



Universidad de Las Américas

Actividad 1: Limpieza de datos

Francis Nikolai Zapata Correa

Gestión de Base de Datos (Master en Ciencia de Datos y BI 2025)

Miguel Ponce Proaño

24 de febrero de 2026

Contenido

1. Descripción del problema: 3

2. Proponga un formato JSON:..... 3

3. Proponga al menos dos mejoras en el conjunto de datos: 5

1. Descripción del problema:

La base de datos presenta múltiples problemas de calidad que requieren ser solucionados para permitir un análisis correcto y consistente. La columna **“OriginalCrimeTypeName”** contiene una mezcla de códigos policiales, abreviaturas, errores tipográficos, duplicados parciales y descripciones poco claras de los crímenes, como por ejemplo: *Traffic Stop, Adv To Co A, 22500e* o *519*. Esto dificulta la interpretación y comprensión de los datos sin conocimiento previo de los códigos y la terminología policial, además de generar inconsistencias en la agrupación de eventos similares. Para resolver esto, se realizaron varias acciones de limpieza: se corrigieron errores tipográficos (por ejemplo, *Attemptted* → *Attempted*, *Suicide Attemptt* → *Suicide Attempt*, *Reporting Officerad Rage* → *Reporting Officer Road Rage*), se estandarizó el formato de texto usando capitalización consistente, y se reemplazaron códigos o abreviaturas por descripciones completas y entendibles. Posteriormente, se creó una nueva columna **“CrimeCategory”** que clasifica cada evento en categorías generales y homogéneas, tales como: crimen violento, crimen contra la propiedad, infracción de tránsito, delitos relacionados con drogas, actividades sospechosas, disturbios públicos, salud mental, personas sin hogar, administración policial y delitos juveniles, lo que permite agrupar los datos de manera lógica para análisis estadístico y reportes. La columna **“CallDateTime”**, que combinaba información redundante de **“OffenseDate”** y **“CallTime”**, fue eliminada para simplificar la estructura del dataset. En la columna **“Disposition”**, los valores *Not recorded* se reemplazaron por *NR* para mantener consistencia en la codificación de resultados de llamadas. En la columna **“City”**, todos los valores faltantes o *NA* se completaron con *San Francisco*, y en la columna **“State”** se agregó *CA*, dado que todos los registros pertenecen a esta jurisdicción. Finalmente, la columna **“Range”** fue eliminada por no aportar información útil al análisis. Con estas acciones, el dataset queda estandarizado, más legible, libre de errores tipográficos y duplicados parciales, y estructurado para facilitar análisis estadísticos, categorización de delitos y generación de reportes.

2. Proponga un formato JSON:

El dataset original en formato CSV fue transformado a JSON para facilitar su manipulación en aplicaciones modernas y mantener la estructura de los datos de forma jerárquica y legible. En el proceso se aplicaron las siguientes transformaciones y limpiezas:

1. Eliminación de campos redundantes o innecesarios:

- Se borraron las columnas CallDateTime y Range porque no aportaban información útil.
- Se consolidaron campos de información incompleta: los valores NA o vacíos en City se reemplazaron por "San Francisco" y en State también se completó como "CA".
- En Disposition, el valor "Not recorded" se reemplazó por "NR" para unificar el formato.

2. Corrección de errores tipográficos y estandarización:

- Se corrigieron errores como "Attemptted" → "Attempted", "Suicide Attemptt" → "Suicide Attempt", "Reporting Officerad Rage" → "Reporting Officer Road Rage", entre otros.
- Se capitalizó de manera consistente la columna OriginalCrimeTypeName para mantener un formato uniforme en todo el dataset.

3. Clasificación de tipos de crimen:

- Se añadió una nueva columna CrimeCategory para agrupar los crímenes en categorías generales como: "violent crime", "property crime", "traffic crime", "drug related", "suspicious", "public disturbance", "mental health", "homeless related", "police admin", "juvenile".
- Esto permite filtrar y analizar los datos más fácilmente, eliminando la necesidad de interpretar códigos o descripciones muy específicas.

4. Estructura JSON generada:

- Cada fila del CSV se convirtió en un **documento JSON individual**, donde cada columna es una clave y su valor es el contenido de esa fila.
- Se utilizó pretty = TRUE y auto_unbox = TRUE en R (jsonlite::toJSON) para que los valores simples no queden dentro de vectores y el archivo sea legible y fácil de interpretar.

Ejemplo de estructura de un documento JSON (simplificado):

```
{
  "CrimeType": "Traffic Stop",
  "CrimeCategory": "traffic crime",
  "OffenseDate": "2023-01-15",
```

```
"CallTime": "14:30",  
"Disposition": "NR",  
"City": "San Francisco",  
"State": "CA"  
}
```

3. Proponga al menos dos mejoras en el conjunto de datos:

Implementación de validación de datos en el momento de captura:

- **Problema actual:** Muchas entradas presentan errores tipográficos, valores nulos o códigos desconocidos.
- **Mejora propuesta:** Configurar formularios de captura digital con listas desplegables para delitos, categorías y disposiciones. También implementar validaciones automáticas para fechas y formatos de texto.
- **Procedimiento:** Usar un sistema de entrada digital conectado a la base de datos policial, con campos obligatorios, menús predefinidos y verificación de consistencia antes de guardar el registro. Esto reducirá errores tipográficos y valores vacíos.

Agregar una columna de geocodificación estandarizada:

- **Problema actual:** La columna City y State tiene valores vacíos y no permite análisis geoespacial confiable.
- **Mejora propuesta:** Incluir latitud y longitud para cada incidente, basados en direcciones exactas o coordenadas GPS, además de mantener City y State.
- **Procedimiento:** Al registrar el incidente, integrar un sistema que capture coordenadas GPS del lugar del hecho o utilice geocodificación de la dirección proporcionada. Esto permitirá análisis geoespacial, mapas de calor de crímenes y una mejor planificación de recursos.

Historial de actualizaciones:

- Registrar cambios en los datos originales (por ejemplo, correcciones de tipografía o categorizaciones) mediante un log de modificaciones. Esto garantiza trazabilidad y auditoría de los datos.