



Taller 2

Francis Zapata

Acrónimos

ML Machine Learning

AI Artificial Intelligence

EDA Exploratory Data Analysis

CV Cross Validation



Tabla de contenidos

Cargar librerías	4
Datos	4
Análisis Exploratorio de datos (EDA)	4
Cambio de nivel de referencia para las variables explicativas y categóricas	7
Regresión Logística	7
Particionamiento	7
Creación de la receta	8
Especificación genérica del modelo	8
Creación de Flujo de Trabajo	8
Ajuste del Modelo	9
Explorar el modelo	10
Evaluación del Modelo	10
Estimación o predicción de la partición de test	10
Matriz de confusión	11
Métricas	12
ROC	13
Otra forma de métricas	14
Maximización de Youden	15
Curva ROC	17
Conclusiones	18
Exploración y Preprocesamiento de los Datos:	18
Análisis Exploratorio de Datos (EDA):	18
Variables Categóricas:	19
Modelo de Regresión Logística:	19
Coeficientes del Modelo:	19
Evaluación del Modelo:	19
Métricas de Evaluación:	19
Matriz de Confusión:	20
Optimización del Umbral (Maximización de Youden):	20
Conclusiones Finales:	20

Indice de figuras

1	Histograma de datos	5
2	Gráfico de frecuencias	6
3	Matriz de confusión	12
4	ROC	14



Indice de tablas

5	Gráfica de punto de corte	16
6	Gráfica de punto de corte	17
7	Curva de ROC_2	18

Indice de tablas

1	Matriz de Correlaciones	6
---	-----------------------------------	---



Cargar librerías

```
pacman::p_load(tidyverse, tidymodels, janitor, broom, kableExtra, GGally, performance, gtsummary)
```

Datos

```
setwd("C:/Users/NW/Documents/Data analisis/UNIDAD 4/Talleres/UNIDAD 4 TALLERES/")
datos<- read.csv(file = "empleados.csv")
```

Análisis Exploratorio de datos (EDA)

Vamos a usar la librería **inspectdf**

```
catalog_var<- inspect_types(datos)

inspect_num(datos)
```

```
# A tibble: 6 x 10
  col_name      min      q1 median  mean      q3      max      sd pcnt_na hist
  <chr>      <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <named >
1 salary    29849. 70379. 88556. 9.41e4 1.17e5 2.12e5 3.76e4      0 <tibble>
2 weekly_hours 40      47      49 5.00e1 5.2 e1 6.6 e1 4.82e0      0 <tibble>
3 yrs_at_comp~ 0        3        5 7.01e0 9 e0 4 e1 6.13e0      0 <tibble>
4 yrs_since_p~ 0        0        1 2.19e0 3 e0 1.5 e1 3.22e0      0 <tibble>
5 previous_co~ 1        2        3 3.24e0 4 e0 7 e0 1.58e0      0 <tibble>
6 miles_from_~ 1        2        7 9.19e0 1.4 e1 2.9 e1 8.11e0      0 <tibble>
```

```
valor_cat<- inspect_cat(datos)
show_plot(inspect_num(datos))
```



Histograms of numeric columns in df::datos




Figura 1: Histograma de datos

```
correlaciones<- inspect_cor(datos[,c(4,5,7,8,9,13)])  
  
kable(correlaciones, caption = "Matriz de Correlaciones", format = "latex")%>%  
  kable_styling(latex_options = c("scale_down"))  
  
show_plot(valor_cat)
```



Tabla 1: Matriz de Correlaciones

col_1	col_2	corr	p_value	lower	upper	pcent_nna
yrs_since_promotion	yrs_at_company	0.6184089	0.0000000	0.5858031	0.6490159	100
previous_companies	weekly_hours	0.3487306	0.0000000	0.3030056	0.3928536	100
weekly_hours	salary	-0.1999940	0.0000000	-0.2485797	-0.1504044	100
previous_companies	salary	-0.1008127	0.0001128	-0.1511610	-0.0499426	100
miles_from_home	weekly_hours	0.0670390	0.0102379	0.0159663	0.1177628	100
yrs_at_company	weekly_hours	-0.0623315	0.0169687	-0.1130985	-0.0112399	100
miles_from_home	salary	-0.0583759	0.0253597	-0.1091775	-0.0072701	100
yrs_since_promotion	salary	-0.0415544	0.1114763	-0.0924853	0.0095935	100
previous_companies	yrs_at_company	-0.0349174	0.1810962	-0.0858915	0.0162390	100
previous_companies	yrs_since_promotion	-0.0320192	0.2200557	-0.0830107	0.0191396	100
miles_from_home	previous_companies	0.0246510	0.3450843	-0.0265099	0.0756830	100
yrs_at_company	salary	-0.0211615	0.4176437	-0.0722108	0.0299984	100
yrs_since_promotion	weekly_hours	-0.0115159	0.6591589	-0.0626065	0.0396349	100
miles_from_home	yrs_since_promotion	0.0100288	0.7008904	-0.0411197	0.0611250	100
miles_from_home	yrs_at_company	0.0095077	0.7157390	-0.0416400	0.0606057	100

Frequency of categorical levels in df::datos

Gray segments are missing values




Figura 2: Gráfico de frecuencias



Cambio de nivel de referencia para las variables explicativas y categóricas

```
class(datos$marital_status)
```

```
[1] "character"
```

```
datos$marital_status<- as.factor(datos$marital_status)
levels(datos$marital_status)
```

```
[1] "Divorced" "Married" "Single"
```

```
datos$marital_status<- relevel(datos$marital_status, ref = "Single")
levels(datos$marital_status)
```

```
[1] "Single" "Divorced" "Married"
```

Regresión Logística

La variable a predecir es `left_company` (dejar la compañía)

Particionamiento

```
datos$left_company<- as.factor(datos$left_company)
datos$left_company<- relevel(datos$left_company, ref = "Yes")
levels(datos$left_company)
```

```
[1] "Yes" "No"
```

```
class(datos$left_company)
```

```
[1] "factor"
```

```
str(datos$left_company)
```

```
Factor w/ 2 levels "Yes","No": 1 2 1 2 2 2 2 2 2 2 ...
```



```
set.seed(12345)

conf_part<- initial_split(datos, prop = 0.8, strata = left_company)
datos_train<- training(conf_part)
datos_test<- testing(conf_part)
```

Creación de la receta

```
receta_reglog<- recipe(left_company~.,data=datos_train) |>
  step_dummy(all_nominal_predictors())

receta2<- recipe(left_company~weekly_hours + yrs_at_company + yrs_since_promotion + performance,
  data=datos_train) |>
  step_dummy(all_nominal_predictors())
```

Especificación genérica del modelo

```
modelo_reg_log<- logistic_reg() |>
  set_engine("glm") |>
  set_mode("classification")
```

Creación de Flujo de Trabajo

```
flujo_trabajo<- workflow() |>
  add_recipe(receta2) |>
  add_model(modelo_reg_log)

flujo_trabajo
```

```
== Workflow =====
Preprocessor: Recipe
Model: logistic_reg()

-- Preprocessor -----
1 Recipe Step

* step_dummy()
```



```
-- Model -----
Logistic Regression Model Specification (classification)
```

```
Computational engine: glm
```

Ajuste del Modelo

```
ajuste_reg_log<- fit(flujo_trabajo, data = datos_train)
ajuste_reg_log
```

```
== Workflow [trained] =====
Preprocessor: Recipe
Model: logistic_reg()
```

```
-- Preprocessor -----
1 Recipe Step
```

```
* step_dummy()
```

```
-- Model -----
```

```
Call: stats::glm(formula = ..y ~ ., family = stats::binomial, data = data)
```

Coefficients:

	(Intercept)	weekly_hours
	75.5080	-1.3756
	yrs_at_company	yrs_since_promotion
	0.2018	-0.2576
performance_rating_Exceptional	performance_rating_Meets.Expectations	
3.0868	-1.6328	
performance_rating_Minimally.Effective	performance_rating_Not.Effective	
-2.0304	-1.6384	

```
Degrees of Freedom: 1174 Total (i.e. Null); 1167 Residual
```

```
Null Deviance: 1037
```

```
Residual Deviance: 112.9 AIC: 128.9
```



Explorar el modelo

```
ajuste_reg_log |>
  pluck("fit",2,4) |>
  summary()
```

Call:

```
stats::glm(formula = ..y ~ ., family = stats::binomial, data = data)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	75.50799	8.89416	8.490	< 2e-16 ***
weekly_hours	-1.37564	0.16383	-8.397	< 2e-16 ***
yrs_at_company	0.20183	0.05202	3.880	0.000104 ***
yrs_since_promotion	-0.25760	0.10088	-2.554	0.010662 *
performance_rating_Exceptional	3.08681	1.33255	2.316	0.020533 *
performance_rating_Meets.Expectations	-1.63275	0.62455	-2.614	0.008941 **
performance_rating_Minimally.Effective	-2.03041	0.81236	-2.499	0.012440 *
performance_rating_Not.Effective	-1.63840	2.23162	-0.734	0.462841

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1036.53 on 1174 degrees of freedom

Residual deviance: 112.88 on 1167 degrees of freedom

AIC: 128.88

Number of Fisher Scoring iterations: 9

Evaluación del Modelo

Estimación o predicción de la partición de test

```
pred<- augment(ajuste_reg_log, datos_test)
pred
```



```
# A tibble: 295 x 16
  .pred_class .pred_Yes .pred_No left_company department job_level salary
  <fct>       <dbl>    <dbl> <fct>      <chr>         <chr>    <dbl>
1 Yes        0.875      0.125 Yes       Sales        Director 1.19e5
2 No         0.0000236    1.00 No        IT and Anal~ Director 1.17e5
3 No         0.000400     1.00 No        Sales        Associate 4.20e4
4 No         0.000277     1.00 No        IT and Anal~ Manager  6.71e4
5 No         0.0000990     1.00 No        Marketing   Manager  6.99e4
6 No         0.465       0.535 Yes       Marketing   Director 1.09e5
7 No         0.00000000229 1.00 No        Sales        Senior M~ 8.40e4
8 Yes        0.987       0.0130 Yes       Sales        Associate 3.85e4
9 Yes        0.869       0.131 No        Research    Senior M~ 8.28e4
10 Yes       0.830       0.170 Yes       Marketing   Associate 4.18e4
# i 285 more rows
# i 9 more variables: weekly_hours <int>, business_travel <chr>,
#   yrs_at_company <int>, yrs_since_promotion <int>, previous_companies <int>,
#   job_satisfaction <chr>, performance_rating <chr>, marital_status <fct>,
#   miles_from_home <int>
```

Matriz de confusión

```
conf_mat(pred, truth = left_company, estimate = .pred_class) |>
  autoplot(type="heatmap")
```




Figura 3: Matriz de confusión

Métricas

```
metricas_rlog<- pred |>
  metrics(truth = left_company, estimate = .pred_class)

metricas_rlog
```

```
# A tibble: 2 x 3
  .metric .estimator .estimate
  <chr>   <chr>       <dbl>
1 accuracy binary     0.956
2 kap     binary     0.842
```

```
library(caret)
rmetrics<- xtabs(data=pred,~.pred_class+left_company)

confusionMatrix(rmetrics)
```



Confusion Matrix and Statistics

```
      left_company
.pred_class Yes  No
      Yes   43   8
      No    5 239

      Accuracy : 0.9559
      95% CI : (0.9258, 0.9763)
      No Information Rate : 0.8373
      P-Value [Acc > NIR] : 2.042e-10

      Kappa : 0.8422

      Mcnemar's Test P-Value : 0.5791

      Sensitivity : 0.8958
      Specificity : 0.9676
      Pos Pred Value : 0.8431
      Neg Pred Value : 0.9795
      Prevalence : 0.1627
      Detection Rate : 0.1458
      Detection Prevalence : 0.1729
      Balanced Accuracy : 0.9317

      'Positive' Class : Yes
```

ROC

```
autoplot(roc_curve(pred, left_company, .pred_Yes))
```




Figura 4: ROC

Otra forma de métricas

```
library(epiR)
summary(epi.tests(rmetrics))
```

	statistic	est	lower	upper
1	ap	0.17288136	0.131513769	0.2209610
2	tp	0.16271186	0.122473913	0.2098784
3	se	0.89583333	0.773422339	0.9653019
4	sp	0.96761134	0.937181298	0.9859151
5	diag.ac	0.95593220	0.925821548	0.9763302
6	diag.or	256.92500000	80.255817596	822.5005688
7	nndx	1.15815180	1.051284799	1.4072543
8	youden	0.86344467	0.710603637	0.9512170
9	pv.pos	0.84313725	0.714123713	0.9297592
10	pv.neg	0.97950820	0.952829503	0.9933137
11	lr.pos	27.65885417	13.894818282	55.0573745
12	lr.neg	0.10765342	0.046945534	0.2468660
13	p.rout	0.82711864	0.779039041	0.8684862



14	p.rin	0.17288136	0.131513769	0.2209610
15	p.tpdn	0.03238866	0.014084852	0.0628187
16	p.tndp	0.10416667	0.034698122	0.2265777
17	p.dntp	0.15686275	0.070240833	0.2858763
18	p.dptn	0.02049180	0.006686313	0.0471705

Maximización de Youden

```
library(cutpointr)
my<- cutpointr(
  data = pred,
  x     = .pred_Yes,
  class=left_company,
  method=maximize_metric,
  metric=youden,
  boot_runs=100
)
my |> t()
```

```

              [,1]
direction      ">="
optimal_cutpoint 0.03772145
method          "maximize_metric"
youden         0.9068826
acc            0.9220339
sensitivity      1
specificity     0.9068826
AUC             0.990722
pos_class       "Yes"
neg_class       "No"
prevalence      0.1627119
outcome         "left_company"
predictor       ".pred_Yes"
data            tbl_df,2
roc_curve       roc_cutpointr,10
boot            tbl_df,23
```

```
my |> plot_metric()
```




Figura 5: Gráfica de punto de corte

```
#| fig.cap: Curva de ROC  
plot_roc(my)
```




Figura 6: Gráfica de punto de corte

Curva ROC

```
library(Epi)
Epi::ROC(form = left_company~weekly_hours + yrs_at_company + yrs_since_promotion + performan
```




Figura 7: Curva de ROC_2

Conclusiones

Exploración y Preprocesamiento de los Datos:

Análisis Exploratorio de Datos (EDA):

- Se realizó un análisis de variables numéricas (como salary, weekly_hours, yrs_at_company, etc.), lo que permitió visualizar distribuciones y entender las características de los datos.
- Se aplicaron análisis de correlaciones, como se muestra en la tabla de correlaciones, destacando relaciones significativas entre variables, por ejemplo:
- yrs_since_promotion y yrs_at_company tienen una correlación moderada positiva (0.62), lo que indica que los empleados con más tiempo en la empresa tienden a haber sido promovidos más veces.
- weekly_hours y salary tienen una correlación negativa (-0.20), sugiriendo que las horas de trabajo semanales no aumentan proporcionalmente con el salario.



Variables Categóricas:

- Se cambiaron los niveles de referencia de algunas variables categóricas, como `marital_status` (se reordenaron los niveles para que “Single” sea la referencia), lo cual es crucial para la interpretación de los coeficientes en la regresión logística.

Modelo de Regresión Logística:

- Se construyó un modelo de regresión logística para predecir si un empleado deja la empresa (`left_company`). El modelo fue ajustado utilizando varias variables predictoras como `weekly_hours`, `yrs_at_company`, `yrs_since_promotion`, y `performance_rating`.

Coeficientes del Modelo:

- `weekly_hours` tiene un coeficiente negativo (-1.38), lo que sugiere que a medida que aumentan las horas semanales de trabajo, disminuye la probabilidad de que un empleado deje la empresa.
- `yrs_at_company` tiene un coeficiente positivo (0.20), lo que indica que con el tiempo en la empresa, los empleados tienen una mayor probabilidad de quedarse.
- `performance_rating` tiene un impacto significativo, especialmente las categorías de “Exceptional” y “Meets Expectations”, que aumentan la probabilidad de quedarse, mientras que las categorías de “Minimally Effective” y “Not Effective” disminuyen esa probabilidad.

Evaluación del Modelo:

Métricas de Evaluación:

- El modelo tiene una exactitud (`accuracy`) de 95.6%, lo que indica que el modelo tiene una alta capacidad para predecir correctamente si un empleado deja o no la empresa.
- Kappa es 0.842, lo que refleja una excelente concordancia entre las predicciones y la realidad.
- La curva ROC muestra un área bajo la curva (AUC) de 0.99, lo que indica que el modelo tiene una capacidad excepcional para diferenciar entre los empleados que dejan la empresa y los que no lo hacen.



Matriz de Confusión:

- El modelo clasifica correctamente a la mayoría de los empleados que no dejan la empresa (239 predicciones correctas de “No”) y también tiene una tasa de detección aceptable para los empleados que dejan la empresa (43 predicciones correctas de “Yes”).
- Sensibilidad (tasa de verdaderos positivos) es del 89.6%, lo que significa que el modelo detecta adecuadamente a la mayoría de los empleados que dejan la empresa.
- Especificidad (tasa de verdaderos negativos) es del 96.8%, lo que refleja que el modelo también es eficaz en identificar a aquellos que no dejan la empresa.

Optimización del Umbral (Maximización de Youden):

- Al optimizar el umbral del modelo utilizando el índice de Youden, se maximiza la sensibilidad y la especificidad, alcanzando un AUC de 0.99 y una exactitud de 92.2%.

Conclusiones Finales:

- El modelo de regresión logística es muy efectivo para predecir si un empleado dejará la empresa, con una excelente precisión, sensibilidad y especificidad.
- Las variables clave que afectan la decisión de dejar la empresa incluyen el número de horas de trabajo, el tiempo en la empresa, la promoción y la calificación del desempeño. Estas deben ser monitoreadas para intervenir y retener a los empleados.
- Es recomendable ajustar el umbral del modelo para maximizar el índice de Youden, lo que podría mejorar aún más el rendimiento de la predicción.
- Los resultados del modelo sugieren que los empleados con un desempeño excepcional tienen menos probabilidades de dejar la empresa, lo que puede guiar estrategias de retención basadas en el rendimiento.